

PROJET DATA SCIENCE — Détection de fraude

1. Contexte

La Benin Bank, banque située à Cotonou, observe une hausse des transactions frauduleuses (cartes volées, fraude en ligne, activités suspectes).

La banque souhaite développer un système intelligent de détection de fraude capable d'identifier automatiquement les transactions suspectes.

Objectif : construire un modèle capable de prédire si une transaction est frauduleuse ou non.

Le système doit être performant, explicable, éthique et sécurisé.

2. Dataset

Dataset public : Credit Card Fraud Detection (Kaggle)

<https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>

Variable cible : Class

0 = transaction normale

1 = fraude

Attention : les fraudes sont très rares.

3. Organisation

5 étudiants → 1 groupe

4. Travail demandé — Étapes

Étape 1 — Compréhension du problème

- Quel est le problème métier ?
- Quel type de problème ML ?
- Pourquoi la fraude est-elle difficile à détecter ?
- Quelle métrique est la plus importante ? Pourquoi ?
- Quel est le coût d'une erreur (faux positif, faux négatif) ?

Étape 2 — Data Cleaning

- Vérifier valeurs manquantes
- Détecter anomalies / outliers
- Normalisation / scaling
- Analyse du déséquilibre des classes
- Stratégie pour gérer le déséquilibre

Questions :

- Y a-t-il des données manquantes ?
- Le dataset est-il équilibré ?
- Pourquoi le déséquilibre est un problème ?
- Quelle méthode avez-vous choisie ?

Étape 3 — Exploration des données (EDA)

- Distribution fraude vs non fraude
- Analyse du montant
- Corrélations

- Variables influentes
- Visualisations

Questions :

- Quelles sont les variables les plus importantes ?
- Les fraudes ont-elles un comportement différent ?
- Avez-vous trouvé des patterns ?
- Quels insights pour la banque ?

Étape 4 — Machine Learning

Tester au minimum 3 modèles :

- Logistic Regression
- Random Forest
- Gradient Boosting / XGBoost

Évaluation :

- Precision
- Recall
- F1-score
- Matrice de confusion

Questions :

- Quel modèle performe le mieux ?
- Quel modèle détecte le mieux les fraudes ?
- Y a-t-il overfitting ?

- Impact du déséquilibre ?
- Quel modèle recommandez-vous ? Pourquoi ?

Étape 5 — Deep Learning

- Construire un Neural Network simple
- Comparer avec ML classique

Questions :

- Le DL est-il meilleur ?
- Overfitting ?
- Complexité vs gain ?
- Le DL est-il utile ici ?

Étape 6 — Explicabilité

- Importance des variables
- Interprétation du modèle
- Comprendre décisions

Questions :

- Pourquoi une transaction est frauduleuse ?
- Le modèle est-il explicable ?
- Peut-on faire confiance au modèle ?
- Interprétable vs boîte noire ?

Étape 7 — Sécurité & Éthique

- Que se passe-t-il si on bloque un client innocent ?
- Le modèle peut-il être biaisé ?
- Données sensibles / vie privée ?
- Peut-on attaquer le modèle ?
- Décision automatique juste ?
- Recommandations pour la banque ?

5. Livrables

1) Notebook Jupyter

- Code propre
- Commentaires
- Graphiques
- Résultats reproductibles

2) Rapport (8-12 pages)

- Introduction & problème métier
- Data cleaning
- Exploration & insights
- Machine Learning
- Deep Learning
- Explicabilité
- Sécurité & éthique
- Discussion & limites
- Conclusion & recommandations

3) Présentation orale (10–15 min)

- Problème
- Méthode
- Résultats
- Modèle choisi
- Limites
- Éthique
- Recommandations

4) Comparaison finale entre groupes

- Performances
- Approches
- Gestion déséquilibre
- Interprétation
- Choix du modèle

6. Évaluation

- Data cleaning : 15%
- EDA : 15%
- Machine Learning : 20%
- Deep Learning : 10%
- Explicabilité : 10%
- Éthique & sécurité : 10%
- Qualité code : 10%

- Présentation : 10%

7. Bonus (optionnel)

- API

PROJET DATA SCIENCE — Détection de maladies des plantes avec CNN

AgriTech Bénin — Cotonou

1. Contexte

Au Bénin, l'agriculture joue un rôle central dans l'économie et dans les revenus de nombreuses familles. Cependant, les cultures sont régulièrement affectées par des maladies qui réduisent les rendements et fragilisent les exploitations agricoles.

Dans de nombreuses zones, l'accès rapide à un expert agronome est limité. Une solution d'intelligence artificielle pourrait aider à détecter automatiquement certaines maladies à partir d'images de feuilles de plantes prises avec un téléphone portable.

Une start-up fictive, **AgriTech Bénin**, souhaite développer un système intelligent capable d'identifier automatiquement l'état de santé d'une plante à partir d'une image.

Objectif : construire un modèle de vision par ordinateur basé sur un **CNN** capable de classer une image de feuille comme saine ou malade, ou d'identifier le type de maladie.

Le système doit être : **performant, explicable, éthique et robuste.**

2. Dataset

Dataset public recommandé :

PlantVillage Dataset

Ce dataset contient des images de feuilles de plantes avec différentes classes :

- feuilles saines
- feuilles malades
- différents types de maladies selon la plante

Exemples de cultures :

- tomate
- pomme de terre
- poivron

Tu peux adapter le scénario au Bénin, même si le dataset n'est pas local.

Variable cible :

- classe de la maladie
ou
- sain / malade

3. Organisation

5 étudiants → 1 groupe

4. Travail demandé — Étapes

Étape 1 — Compréhension du problème

- Quel est le problème métier ?
- Pourquoi ce problème est-il important pour l'agriculture ?
- Quel type de problème ML ?
- Pourquoi un CNN est-il adapté ici ?
- Quelle métrique est la plus importante ?

Questions :

- Pourquoi utiliser des images ?
- Pourquoi un CNN est plus adapté qu'une régression logistique ici ?
- Quel serait l'intérêt pour un agriculteur ou une coopérative ?

Étape 2 — Préparation des données

- Charger les images
- Vérifier la qualité des images
- Redimensionner les images

- Normaliser les pixels
- Encoder les labels
- Diviser en train / validation / test
- Gérer éventuellement le déséquilibre des classes

Questions :

- Les classes sont-elles équilibrées ?
- Pourquoi faut-il redimensionner les images ?
- Pourquoi normaliser les pixels ?
- Quelles difficultés viennent des images réelles ?

Étape 3 — Exploration des données

- Nombre d'images par classe
- Visualisation de quelques images
- Comparaison entre feuilles saines et malades
- Analyse des classes dominantes
- Observation des difficultés visuelles

Questions :

- Certaines maladies se ressemblent-elles ?
- Les images sont-elles homogènes ?
- Quelles difficultés peut rencontrer le modèle ?
- Quels insights peut-on tirer pour le terrain ?

Étape 4 — Modélisation CNN

Construire au minimum :

- un **CNN simple**
- un **CNN amélioré**
- éventuellement un modèle en **transfer learning**
(ex. MobileNetV2, ResNet, EfficientNet)

Évaluation :

- Accuracy

- Precision
- Recall
- F1-score
- Matrice de confusion

Questions :

- Quel modèle performe le mieux ?
- Quelles classes sont les plus difficiles à détecter ?
- Y a-t-il overfitting ?
- Quel modèle recommandez-vous ? Pourquoi ?

Étape 5 — Amélioration du modèle

- Data augmentation
- Dropout
- Batch normalization
- Early stopping
- Transfer learning

Questions :

- La data augmentation améliore-t-elle les résultats ?
- Le modèle surapprend-il ?
- Le transfer learning apporte-t-il un gain ?
- Quel compromis entre performance et complexité ?

Étape 6 — Explicabilité

- Visualiser les prédictions
- Étudier les erreurs
- Utiliser Grad-CAM ou une méthode simple de visualisation
- Comprendre quelles zones de l'image influencent la décision

Questions :

- Pourquoi le modèle prédit-il maladie ?
- Regarde-t-il réellement la feuille ?

- Le modèle est-il explicable ?
- Peut-on faire confiance à sa décision ?

Étape 7 — Robustesse, sécurité et éthique

- Que se passe-t-il si l'image est floue ?
- Que se passe-t-il si la feuille est partiellement cachée ?
- Le modèle fonctionne-t-il sur des images prises sur le terrain et non en laboratoire ?
- Quels sont les risques d'erreurs pour les agriculteurs ?
- Faut-il une validation humaine ?

Questions :

- Le modèle peut-il se tromper à cause de la qualité de l'image ?
- Peut-il être biaisé par le fond, la lumière, ou l'angle ?
- Une mauvaise prédiction peut-elle entraîner une mauvaise décision agricole ?
- Comment utiliser ce système de manière responsable ?

5. Livrables

1) Notebook Jupyter

- Code propre
- Commentaires
- Visualisations
- Entraînement du CNN
- Résultats reproductibles

2) Rapport (8-12 pages)

- Introduction & contexte
- Préparation des images
- Exploration des données
- CNN et résultats
- Améliorations
- Explicabilité

- Robustesse, éthique et limites
- Conclusion & recommandations

3) Présentation orale (10–15 min)

- Problème
- Dataset
- Architecture CNN
- Résultats
- Difficultés
- Limites
- Recommandations

4) Comparaison finale entre groupes

- Performance
- Approche choisie
- Robustesse
- Interprétation
- Potentiel d'usage réel

6. Évaluation

- Préparation des données : 15%
- Exploration des données : 15%
- CNN / modélisation : 20%
- Amélioration du modèle : 10%
- Explicabilité : 10%
- Robustesse / éthique : 10%
- Qualité du code : 10%
- Présentation : 10%

7. Bonus (optionnel)

- API